

VISÃO COMPUTACIONAL – APRENDIZADO PROFUNDO

Detecção de Equipamentos de Proteção Individual

Preparação do dataset, treinamento, validação e análise dos testes com
YOLO11n

Experimentos de 1, 10 e 30 épocas

Bernardo Gontijo Fernandes
Gabriel Cunha da Rocha
Lethicia de Souza Lira
Kauan Matheus Maloste Martins
Paulo Miguel Castro de Souza

Projeto de detecção de EPIs

10 de setembro de 2026

Resumo

O projeto utiliza YOLO11n para detectar capacetes, óculos de proteção e luvas. A base do Roboflow foi convertida de 14 para três classes e reduzida a um MVP de 10.000 imagens, dividido em 70% para treino, 20% para validação e 10% para teste. Foram comparadas execuções independentes de 1, 10 e 30 épocas. No teste, o mAP@50 evoluiu de 54,38% para 87,09% e 90,88%, respectivamente. A execução de 30 épocas também reduziu erros, principalmente em capacetes, mas a precisão das caixas e a avaliação em ambientes reais permanecem como limitações.

As informações foram conferidas no README, nos scripts, nos CSV/JSON dos experimentos e no histórico da tarefa *Planejar projeto de detecção de EPIs*. Os gráficos de treinamento representam validação; os resultados das pastas de avaliação representam teste.

Sumário

1	Objetivo e evolução do escopo	1
2	Origem e preparação do dataset	1
3	Construção do MVP e divisão 70–20–10	1
4	Ajustes do ambiente e trajetória experimental	3
5	Configuração de treinamento e validação	3
6	Protocolo de teste e interpretação das métricas	3
7	Resultados da validação durante o treinamento	4
8	Resultados dos três testes	5
9	Análise das matrizes de confusão	6
10	Curvas precisão–recall e F1	8
11	Discussão, limitações e conclusões	11
A	Reprodução e evidências	11
	Referências	12

1 Objetivo e evolução do escopo

O MVP localiza três tipos de EPI e fornece classe, confiança e caixa delimitadora. O escopo foi simplificado para **helmet**, **goggles** e **gloves**, deixando a associação com pessoas e a verificação de uso correto para uma etapa futura. O Kaggle foi considerado como fonte adicional, mas não foi incorporado aos experimentos.

2 Origem e preparação do dataset

A base utilizada foi o *Personal Protective Equipment – Combined Model*, versão 8, do Roboflow, com licença CC BY 4.0. A cópia local contém 43.995 imagens, já orientadas e redimensionadas para 640×640 na exportação. Os metadados anunciam 44.002; a diferença de sete imagens não tem causa documentada.

O script `preparar_dataset.py` preservou os arquivos originais e criou uma cópia com o seguinte mapeamento:

Tabela 1: Mapeamento aplicado a cada anotação YOLO.

Classe original	Índice original	Classe final	Índice final
Hardhat	3	helmet	0
Goggles	2	goggles	1
Gloves	1	gloves	2

As demais classes foram removidas das anotações. As coordenadas das caixas foram mantidas, e imagens sem os três EPIs receberam rótulos vazios para funcionar como exemplos negativos. Também foram organizadas as pastas de imagens e rótulos, renomeada a partição **valid** para **val** e corrigidos os caminhos e nomes das classes no YAML.

A conferência estrutural não encontrou imagens sem rótulo, anotações órfãs ou coordenadas inválidas. Isso não substitui revisão visual: não há comprovação de revisão completa no Label Studio ou de remoção de imagens semelhantes entre partições.

3 Construção do MVP e divisão 70–20–10

A base convertida tinha 42.428 caixas de capacete, 4.188 de óculos e 4.669 de luvas, além de 22.607 imagens negativas. Para reduzir o custo e o desequilíbrio, o script `criar_dataset_mvp.py` preservou todas as imagens com óculos ou luvas e limitou as imagens apenas com capacetes e as negativas, usando semente 42 dentro das partições existentes.

Tabela 2: Composição efetiva das 10.000 imagens do MVP.

Partição	Óculos e/ou luvas	Apenas capacete	Negativas	Total
Treino	4.200	1.050	1.750	7.000
Validação	1.141	359	500	2.000
Teste	570	180	250	1.000
Total	5.911	1.589	2.500	10.000

Fonte: `dataset_epi_mvp/resumo.txt`. Prioritárias: imagens com óculos ou luvas.




Figura 1: Contagens de objetos antes e depois da seleção. Os eixos verticais têm escalas diferentes para tornar legíveis os valores de cada base. A redução ocorre em capacetes; todas as caixas de óculos e luvas são preservadas.

O MVP passou a conter 4.504 caixas de capacete, 4.188 de óculos e 4.669 de luvas. Os negativos representam 25% de cada partição, mantendo exemplos de fundo sem dominar o treinamento.

A divisão **70–20–10** acompanha a proporção aproximada da base original: 7.000 imagens atualizam os pesos, 2.000 permitem acompanhar a aprendizagem e selecionar o modelo, e 1.000 ficam reservadas para teste. A validação maior ajuda a observar oscilações, mas essa proporção foi uma escolha prática, não uma configuração comprovadamente superior por experimentação.

4 Ajustes do ambiente e trajetória experimental

A execução no Windows exigiu instalar o PyTorch com CUDA para utilizar a RTX 3060 Laptop GPU. Para reduzir falhas de RAM, foram adotados `workers=0` e `cache=False`. A primeira época na base completa levou cerca de 28 minutos; isso motivou a redução do dataset e o aumento do lote de 4 para 16.

A primeira tentativa de 10 épocas, `teste_mvp-2`, terminou na segunda porque `patience=1` interrompeu o treino após uma queda da validação. O ajuste para 5 permitiu completar `teste_mvp-3`, que é a execução de 10 épocas utilizada nesta comparação. O treinamento de 30 épocas usou paciência 8 e também foi concluído.

5 Configuração de treinamento e validação

As três execuções partiram dos pesos pré-treinados `yolo11n.pt`, com resolução 640, lote 16, GPU 0, semente 42 e otimização automática. O YOLO11n foi mantido por ser uma opção leve para o MVP. O treinamento aplicou transformações de cor, escala, translação, espelhamento e Mosaic.

A validação ocorreu ao final de cada época, sem atualizar os pesos. O `best.pt` foi escolhido pelo maior `mAP@50-95` de validação, alcançado nas épocas 1, 10 e 30 das respectivas execuções. `last.pt` registra o estado final.

As execuções são independentes, não continuções do mesmo treinamento. A taxa de aprendizado depende do total de épocas. Além disso, `close_mosaic=10` desativa o Mosaic desde o início na execução de 10 épocas e a partir da época 21 na de 30. A execução de 1 época mantém Mosaic e não realiza o mesmo aquecimento inicial. Essas diferenças explicam trajetórias distintas mesmo com a mesma semente.

6 Protocolo de teste e interpretação das métricas

Cada `best.pt` foi avaliado com `split="test"` nas mesmas 1.000 imagens, contendo 496 capacetes, 402 óculos e 430 luvas. As pastas dos resultados são:

1 época	<code>avaliacao_1-epoch_test</code>
10 épocas	<code>avaliacao_10-epochs_test</code>
30 épocas	<code>avaliacao_final_test</code>

- **Precisão:** proporção das detecções que estão corretas.
- **Recall:** proporção dos objetos anotados que foram encontrados.
- **F1:** equilíbrio entre precisão e recall.
- **mAP@50:** média do AP das classes com sobreposição mínima de 50% entre caixas (IoU).
- **mAP@50-95:** média em limiares de IoU de 0,50 a 0,95; exige localização mais precisa.

Nas matrizes, as colunas representam a classe verdadeira e as linhas a previsão. A coluna *background* conta previsões sem correspondência; a linha *background*, objetos não encontrados. Fundo não é uma quarta classe. A implementação usa confiança 0,25 e IoU 0,45 na matriz; os AP percorrem vários limiares de confiança. Portanto, suas contagens não coincidem diretamente com as médias dos JSON.

7 Resultados da validação durante o treinamento

O $mAP@50$ de validação foi de 53,66%, 84,23% e 87,41% nas execuções de 1, 10 e 30 épocas; o $mAP@50-95$ foi de 22,01%, 44,99% e 47,52%. Na execução longa, ambos superaram o resultado final da de 10 épocas a partir da época 21.




Figura 2: Evolução da validação em execuções independentes. O ponto isolado representa a execução de 1 época. A linha vertical pontilhada marca o início da época 21, quando o Mosaic é desativado na execução de 30 épocas. A perda de classificação utiliza escala logarítmica.

As perdas finais de treino e validação diminuíram de 10 para 30 épocas, sem degradação sustentada das métricas até o fim observado. Isso sugere aprendizagem útil, mas não prova ausência de sobreajuste. As oscilações da perda de classificação devem ser lidas junto com a tendência dos demais indicadores.




Figura 3: Painel original do treinamento de 30 épocas, com perdas e métricas. As curvas *val* e as métricas deste painel são de validação; não pertencem ao teste.

8 Resultados dos três testes

Tabela 3: Resultados no conjunto de teste, extraídos dos JSON. Valores em porcentagem.

Execução	Precisão	Recall	mAP@50	mAP@50–95
1 época	59,76	52,63	54,38	21,68
10 épocas	78,24	86,75	87,09	46,66
30 épocas	85,14	88,37	90,88	49,91
Ganho 1 → 10 (p.p.)	+18,48	+34,12	+32,71	+24,98
Ganho 10 → 30 (p.p.)	+6,89	+1,61	+3,79	+3,25




Figura 4: Síntese das métricas gerais e do AP@50 por classe no mesmo conjunto de teste. Os números dos gráficos são arredondados para uma casa decimal; as tabelas usam duas.

O maior salto ocorreu entre 1 e 10 épocas, especialmente no recall. De 10 para 30, a precisão cresceu mais que o recall, indicando menor proporção de detecções incorretas. Entretanto, a diferença entre mAP@50 de 90,88% e mAP@50–95 de 49,91% mostra que o posicionamento rigoroso das caixas ainda é uma limitação.

Tabela 4: AP por classe no teste. Todos os valores em porcentagem.

Classe	Métrica	1 época	10 épocas	30 épocas
Capacete	AP@50	39,92	71,61	79,69
	AP@50–95	14,37	35,79	42,11
Óculos	AP@50	65,02	96,29	97,80
	AP@50–95	26,07	56,65	59,09
Luvas	AP@50	58,19	93,38	95,15
	AP@50–95	24,59	47,54	48,53

Capacetes tiveram o maior ganho de 10 para 30 épocas: +8,09 pontos percentuais em AP@50 e +6,33 em AP@50–95, mas continuaram abaixo das outras classes. Os exemplos salvos mostram capacetes pequenos, distantes e parcialmente ocultos. Óculos e luvas já atingem AP@50 elevado, porém o AP@50–95 confirma espaço para melhorar suas caixas.

9 Análise das matrizes de confusão

9.1 Uma época





Figura 5: Matriz original do teste de 1 época. Linhas: predição; colunas: referência. Células vazias correspondem a contagens nulas no gráfico.


A matriz de 1 época registra 352 acertos, 974 objetos sem previsão correspondente, 103 previsões sem correspondência e duas luvas confundidas com capacete. O baixo número de falsos positivos não indica superioridade: o modelo também deixa de recuperar grande parte dos objetos no limiar usado.

O recall da matriz difere do JSON porque a confiança fixa de 0,25 é maior que a confiança do máximo da curva F1 da execução curta, próxima de 0,110. A avaliação de uma única época serve principalmente para verificar o funcionamento do pipeline.

9.2 De 10 para 30 épocas



(a) Teste de 10 épocas.



(b) Teste de 30 épocas.


Figura 6: Matrizes originais das execuções completas, no mesmo conjunto de 1.328 objetos. As barras de cor são ajustadas automaticamente por figura; a comparação quantitativa deve usar os números das células.

Os falsos positivos de fundo caíram de 465 para 329 (**29,25%**), e os objetos sem previsão de 122 para 100 (**18,03%**). Capacetes responderam pela maior redução: 273 para 169 falsos positivos e 98 para 74 omissões. Não houve confusão registrada entre as três classes nessas duas matrizes.


Óculos tiveram três omissões em 10 épocas e seis em 30, apesar da melhora de AP. Isso é possível porque a matriz mostra um único ponto de confiança, enquanto AP resume a curva completa.

10 Curvas precisão–recall e F1

10.1 Precisão–recall



(a) 1 época.



(b) 10 épocas.

Figura 7: Curvas PR originais dos testes de 1 e 10 épocas, avaliadas em IoU 0,50. A legenda informa o AP por classe e o mAP; os valores exibidos nos gráficos têm arredondamento próprio.




Figura 8: Curva PR original do teste de 30 épocas, com IoU 0,50. A área sob a curva é maior para óculos e luvas do que para capacetes.

As curvas PR mostram a evolução além de um limiar fixo: após 1 época, a precisão cai rapidamente ao aumentar o recall; em 10 e 30 épocas, óculos e luvas mantêm boa precisão em uma faixa maior. Capacetes ainda apresentam a menor área sob a curva, embora melhorem na execução longa.

10.2 F1 e confiança




Figura 9: F1 em função da confiança. A figura de 30 épocas recebe maior área para facilitar a leitura do intervalo de operação da execução principal. As tabelas e o texto explicitam os valores das legendas menores.

Os máximos médios de F1 indicados nas legendas são aproximadamente 0,54 em confiança 0,110; 0,82 em 0,363; e 0,86 em 0,389, para 1, 10 e 30 épocas. A execução longa mantém F1 elevado em uma faixa mais ampla, principalmente para óculos e luvas.

Esses pontos descrevem o teste e não são limiares já aprovados para uso real. A confiança operacional deve ser escolhida na validação, conforme o custo de omissões e falsos alarmes.

11 Discussão, limitações e conclusões

A conversão das classes e o MVP tornaram o treinamento viável e mais equilibrado. O ajuste da paciência evitou encerramento prematuro, e a execução de 30 épocas apresentou o melhor resultado observado: **85,14% de precisão, 88,37% de recall, 90,88% de mAP@50 e 49,91% de mAP@50–95**. O principal avanço foi a detecção de capacetes com menos erros.

As conclusões devem considerar quatro limitações: houve uma execução por configuração, sem intervalos de confiança; não foi comprovada deduplicação entre partições; o teste tem distribuição selecionada pelo MVP; e as imagens auditadas contêm anotações de apenas um tipo de EPI por imagem, sem coocorrência entre as classes. Portanto, ainda falta avaliar cenas com vários tipos simultâneos e câmeras do ambiente pretendido.

As próximas prioridades são revisar caixas e omissões, especialmente de capacetes, e avaliar em um conjunto externo com cenas independentes. Como o teste atual já foi consultado para três modelos, ele não deve orientar ajustes repetidos. A associação entre EPI e pessoa e a verificação de uso correto também permanecem fora do escopo implementado.

A Reprodução e evidências

Os arquivos `args.yaml` e `results.csv` registram configurações e validação; `metricas_teste.json` registra os testes. O histórico de planejamento explica as mudanças de escopo e os ajustes do ambiente. As cópias dessas evidências e as instruções de compilação estão no pacote LaTeX e em `LEIA-ME.md`.

A matriz normalizada abaixo complementa a comparação: cada coluna soma aproximadamente 1. Na coluna de fundo, 0,51 significa que cerca de 51% das previsões sem correspondência foram capacetes, não que 51% das imagens negativas tiveram falso alarme.




Figura 10: Teste de 30 épocas, normalizado por coluna. O fundo não é uma classe de treinamento. Valores como 0,51 na coluna de fundo descrevem a composição dos falsos positivos, não a probabilidade de falso alarme por imagem negativa.

Referências

- [1] ROBOFLOW. *Personal Protective Equipment – Combined Model*, versão 8. Exportação local, licença CC BY 4.0. <https://universe.roboflow.com/roboflow-universe-projects/personal-protective-equipment-combined-model/dataset/8>.
- [2] EQUIPE DO PROJETO. README, scripts, CSV/YAML de treinamento e JSON/figuras dos testes. Histórico: *Planejar projeto de detecção de EPIs*. Consultados em 10 set. 2026.
- [3] ULTRALYTICS. *Model Training*. <https://docs.ultralytics.com/modes/train/>. Acesso em: 10 set. 2026.
- [4] ULTRALYTICS. *YOLO Performance Metrics*. <https://docs.ultralytics.com/guides/yolo-performance-metrics/>. Acesso em: 10 set. 2026. Critérios conferidos no código local da versão 8.4.146.